

贝叶斯决策

赵海涛

haitaozhao@ecust.edu.cn

大纲

- 贝叶斯决策
- 朴素贝叶斯
- 例子

贝叶斯



- 贝叶斯(约1701-1761) Thomas Bayes, 英国数学家。约1701年出生于伦敦, 做过神甫。1742年成为英国皇家学会会员。1761年4月7日逝世。
- 贝叶斯在数学方面主要研究概率论。他首先将归纳推理法用于概率论基础理论, 并创立了贝叶斯统计理论, 对于统计决策函数、统计推断、统计的估算等做出了贡献。他死后, 理查德·普莱斯(Richard Price)于1763年将他的著作《机会问题的解法》(An essay towards solving a problem in the doctrine of chances)寄给了英国皇家学会, 对于现代概率论和数理统计产生了重要的影响。

贝叶斯决策



- 贝叶斯决策方法是统计模型决策中的一个基本方法，其基本思想是：
 1. 已知类条件概率密度参数表达式和先验概率。
 2. 利用贝叶斯公式转换成后验概率。
 3. 根据后验概率大小进行决策分类。

贝叶斯网络的应用

最早的PathFinder系统，该系统是淋巴疾病诊断的医学系统，它可以诊断60多种疾病，涉及100多种症状;后来发展起来的Internist - I系统，也是一种医学诊断系统，但它可以诊断多达600多种常见的疾病。


1995年，微软推出了第一个基于贝叶斯网的专家系统，一个用于幼儿保健的网站OnParent (www.onparenting.msn.com), 使父母们可以自行诊断。

贝叶斯网络的应用

- (1)故障诊断(diagnose)
- (2)专家系统(expert system)
- (3)规划(planning)
- (4)学习(learning)
- (5)分类(classifying)

贝叶斯决策理论

几个重要的概率公式



- $0 < P(A_i) < 1$
- $P(S) = 1$ (S 是样本空间)
- 如果 A_1, A_2, \dots, A_N 互斥事件 ($P(A_i \cap A_j) = 0, i \neq j$), 则

$$P(A_1 \cup A_2 \cup \dots \cup A_N) = \sum_{i=1}^N P(A_i)$$

几个重要的概率公式


- 条件概率公式

$$P(A | B) = \frac{P(A, B)}{P(B)} \quad P(B | A) = \frac{P(A, B)}{P(A)}$$

- 条件概率的链式法则：

$$P(A, B) = P(A|B)P(B) = P(B|A)P(A)$$

全概率公式



- 如果 A_1, A_2, \dots, A_N 是互斥事件且是对样本空间的一个划分, B 是任意事件, 则有

$$P(B) = \sum_{i=1}^N P(B | A_i)P(A_i)$$

贝叶斯公式

- 贝叶斯公式（贝叶斯准则，贝叶斯定理）：

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}$$

- 如果 A_1, A_2, \dots, A_N 是互斥事件且是对样本空间的一个划分， B 是任意事件，则贝叶斯公式为：

$$P(A_i | B) = \frac{P(B | A_i)P(A_i)}{P(B)}$$

其中

$$P(B) = \sum_{i=1}^N P(B | A_i)P(A_i)$$

独立

- 事件 A 和 B 相互独立:

$$P(A, B) = P(A)P(B)$$

- 由上面的公式, 我们可以得到:

$$P(A|B) = P(A), \quad P(B|A) = P(B)$$


- A 和 B 在给定事件 C 的条件下相互独立:

$$P(A, B|C) = P(A|C)P(B|C)$$

独立

- 事件 A , B 和 C 在给定事件 C 的条件下相互独立, 当且仅当 $P(C) > 0$, 且

$$P(A|B, C) = P(A|C)$$




独立与条件独立

- $P(A, B) \neq P(A)P(B), P(A, B|C) = P(A|C)P(B|C)$

若用 H 表示去吃饭，T 表示不去吃饭，0 表示不上课，1 表示上课。情况可由下表所示：


C	0	1
甲	H	{H T}
乙	H	{H T}
Ω	HH	{HH HT TH TT}

- $P(A, B) = P(A)P(B), P(A, B|C) \neq P(A|C)P(B|C)$



$$P(A \cap B | C) = P(A | C)P(B | C)$$

Assume A and B are independent



- If we are told that C occurred, are A and B independent?

几个例子

- 假设有三个看起来完全一样的盒子，每个盒子都有确定数量的红色和蓝色的球，它们除了颜色之外完全相同。第 i 个盒子中红色球和蓝色的数量分别为 r_i 和 b_i ，其中 $i=1,2,3$ 。本试验就是随机取一个盒子，然后从该盒子中随机取出一个球。结果是红色球。考虑结果为红色球的基础上，计算球属于一号盒子的概率。


几个例子

181. 已知某酒鬼有90%的日子都会出去喝酒，喝酒只去固定三家酒吧。今天警察找了其中两家酒吧都没有找到酒鬼。问：酒鬼在第三家酒吧的几率？

[数学天地]

难度:4星

几个例子



题目：假设你参加一个电视游戏节目，节目现场有三扇门，其中一扇门后面是一辆车，另外两扇门后面则是山羊。主持人让你选择其中的一扇门。不妨假设你选择了一号门吧。主持人故意打开了另外一扇门，比如说三号门，让你看见三号门的后面是山羊。然后主持人问你，“你想改变你的选择，换成二号门吗？”这时候，你会怎么做？

The **Monty Hall problem** is a brain teaser, in the form of a [probability](#) puzzle, loosely based on the American television game show *Let's Make a Deal* and named after its original host, [Monty Hall](#). The problem was originally posed (and solved) in a letter by [Steve Selvin](#) to the *American Statistician* in 1975.^{[1][2]} It became famous as a question from reader Craig F. Whitaker's letter quoted in [Marilyn vos Savant's](#) "Ask Marilyn" column in *Parade* magazine in 1990.^[3]

术语

- 模式状态 ω (随机变量):
 - ✓ ω_1 表示鲈鱼, ω_2 表示三文鱼
- 概率 $P(\omega_1)$ 和 $P(\omega_2)$ (先验):
 - ✓ 先验知识: 有多大的可能性得到一条鲈鱼或一条三文鱼
- 概率密度函数 $p(x)$ (证据):
 - ✓ 对模式的某一特征 x 进行测量, 出现的频率值
(例如, x 是亮度测量)

Note: if x and y are different measurements, $p(x)$ and $p(y)$ correspond to different pdfs: $p_X(x)$ and $p_Y(y)$

术语

- 类条件概率密度 $p(x|\omega_j)$ （似然）：
 - 在模式属于 ω_j 类的条件下，对模式的某一特征 x 进行测量，出现的频率值

右图：三文鱼和鲈鱼的类条件概率密度




FIGURE 2.1. Hypothetical class-conditional probability density functions show the probability density of measuring a particular feature value x given the pattern is in category ω_i . If x represents the lightness of a fish, the two curves might describe the difference in lightness of populations of two types of fish. Density functions are normalized, and thus the area under each curve is 1.0. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons,

术语

- 条件概率 $P(\omega_j|x)$ (后验) :
 - 在给点给特征 x 测量值的条件下, 模式属于 ω_j 类的可能性.

Note: we will be using an uppercase $P(\cdot)$ to denote a probability mass function (pmf) and a lowercase $p(\cdot)$ to denote a probability density function (pdf).

仅使用先验的决策规则

- Decide ω_1 if $P(\omega_1) > P(\omega_2)$; otherwise decide ω_2
- $P(error) = \min[P(\omega_1), P(\omega_2)]$
- 倾向于选择可能出现频率高的类...(在没有其它信息的条件下最优).
- 总是得到相同的决策!
- 只做一次决策是有一定道理的...

运用条件概率进行决策

- 运用贝叶斯公式，后验概率可表示为：

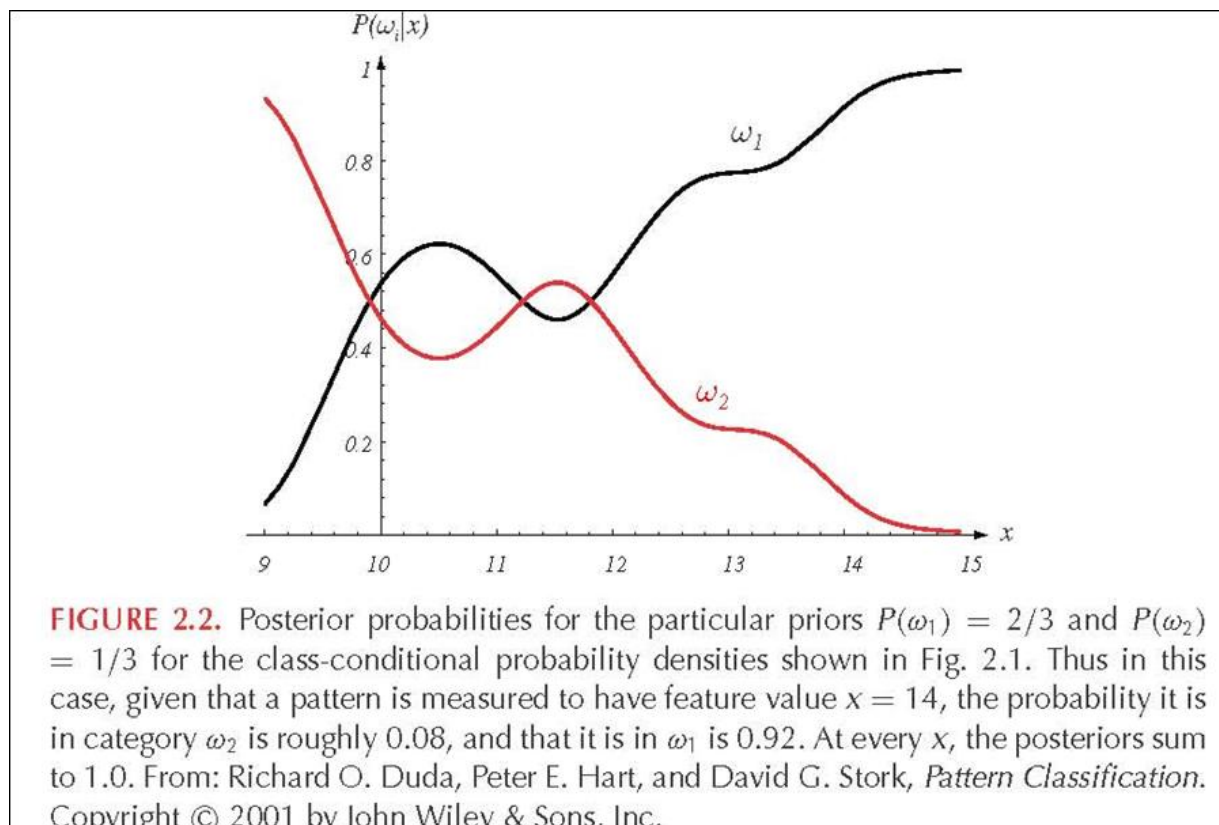
$$P(\omega_j | x) = \frac{p(x | \omega_j)P(\omega_j)}{p(x)} = \frac{\text{likelihood} \times \text{prior}}{\text{evidence}}$$

其中 $p(x) = \sum_{i=1}^2 p(x | \omega_i)P(\omega_i)$

- 贝叶斯决策：若 $P(\omega_1|x) > P(\omega_2|x)$ ，则 $x \in \omega_1$ ；反之，则 $x \in \omega_2$
 - 也可以写为 $p(x|\omega_1)P(\omega_1) > p(x|\omega_2)P(\omega_2)$ ，则 $x \in \omega_1$ ；反之，则 $x \in \omega_2$

运用条件概率进行决策

- $P(\omega_1) = \frac{2}{3}, P(\omega_2) = \frac{1}{3}$



错误概率

- 贝叶斯决策错误概率:


$$P(\text{error} | x) = \begin{cases} P(\omega_1 | x) & \text{if we decide } \omega_2 \\ P(\omega_2 | x) & \text{if we decide } \omega_1 \end{cases}$$

- 平均错误概率:

$$P(\text{error}) = \int_{-\infty}^{+\infty} P(\text{error}, x) dx = \int_{-\infty}^{+\infty} P(\text{error} | x) p(x) dx$$

- 运用贝叶斯准则可得到最优决策, 即使平均错误概率最小化, 因为

$$P(\text{error} | x) = \min [P(\omega_1 | x), P(\omega_2 | x)]$$



*最小风险贝叶斯决策

- 推广一维变量的贝叶斯决策，添加四个条件：
 - 允许使用多于一个的特征
 - 允许多于两种类别状态的情况
 - 允许有其他行为而不仅是判定类别
 - 通过引入一个更一般的损失函数来代替误差概率

令 $\{\omega_1, \dots, \omega_c\}$ 表示 c 个类别集， $\{\alpha_1, \dots, \alpha_a\}$ 表示 a 种可能采取的行为集，风险函数 $\lambda(\alpha_i|\omega_j)$ 描述类别状态为 ω_j 时采取行动 α_i 的风险。令特征向量 \mathbf{x} 表示一个 d 维随机变量。

$$P(\omega_j|\mathbf{x}) = \frac{p(\mathbf{x}|\omega_j)P(\omega_j)}{p(\mathbf{x})}$$

$$\text{其中, } p(\mathbf{x}) = \sum_{j=1}^c p(\mathbf{x}|\omega_j)P(\omega_j)$$

* 贝叶斯风险

- 那么对于这个特征向量 \mathbf{x} 与行为 α_i 相关联的预期损失（即条件风险）就是：

$$R(\alpha_i|\mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j)P(\omega_j|\mathbf{x})$$

其中 $\lambda(\alpha_i|\omega_j)$ 在 ω_j 类情况下，采取行为 α_i 的损失

- 最小化后的总风险值称为贝叶斯风险，记为 R^*

$$R^* = \int_{\mathbf{x}} \min[R(\alpha_1|\mathbf{x}), \dots, R(\alpha_c|\mathbf{x})]p(\mathbf{x})d\mathbf{x}$$

*常用贝叶斯决策规则

- 最小错误率贝叶斯决策

$$\text{0-1损失: } \lambda(\alpha_i|\omega_j) = \begin{cases} 0 & i = j \\ 1 & i \neq j \end{cases} \quad i, j = 1, 2, \dots, c$$

这时的条件风险就是 $R(\alpha_i|\mathbf{x}) = \sum_{j=1}^c \lambda(\alpha_i|\omega_j)P(\omega_j|\mathbf{x}) = 1 - P(\omega_j|\mathbf{x})$

- 带有拒绝域的最小错误率贝叶斯决策

将采样空间划分两个互补的区域：拒绝域 Re 和接受域 Ac （或分类域）。其定义如下：

$$\begin{aligned} Re &= \{\mathbf{x} \mid 1 - \max_j P(\omega_j|\mathbf{x}) > t\} \\ Ac &= \{\mathbf{x} \mid 1 - \max_j P(\omega_j|\mathbf{x}) \leq t\} \end{aligned}$$

其中 t 是阈值。如果样本 \mathbf{x} 位于接受域 Ac ，则可用基于最小错误的贝叶斯决策规则将其分类。

如果 \mathbf{x} 位于拒绝域 Re ，则拒绝对 \mathbf{x} 的分类。

*常用贝叶斯决策规则

- 最小风险贝叶斯决策

以两类分类问题为例，这里行为 α_1 对应于类别判决 ω_1 ，行为 α_2 对应于类别判决 ω_2 。风险函数 $\lambda_{ij} = \lambda(\alpha_i|\omega_j)$ 表示当类别为 ω_j 情况下判为 ω_i 所引起的损失。这样条件风险就可表示为：

$$\begin{aligned}R(\alpha_1|\mathbf{x}) &= \lambda_{11}P(\omega_1|\mathbf{x}) + \lambda_{12}P(\omega_2|\mathbf{x}) \\R(\alpha_2|\mathbf{x}) &= \lambda_{21}P(\omega_1|\mathbf{x}) + \lambda_{22}P(\omega_2|\mathbf{x})\end{aligned}$$

只要比较不同的条件风险，选择其中比较小的那个条件风险，从而确定其类别，即：

$$\text{若 } \frac{p(\mathbf{x}|\omega_1)}{p(\mathbf{x}|\omega_2)} > \frac{(\lambda_{12}-\lambda_{22})P(\omega_2)}{(\lambda_{21}-\lambda_{11})P(\omega_1)}, \text{ 则 } \mathbf{x} \in \omega_1; \text{ 反之, 则 } \mathbf{x} \in \omega_2$$

此时，**最小贝叶斯风险 R^*** 由下式确定：

$$R^* = \int_{\mathbf{x}} \min_i \sum_{j=1}^2 \lambda_{ij} P(\omega_j|\mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

概率或密度函数如何得到？

- 如果概率已知，贝叶斯准则是最优的
- 有两种方式可以得到贝叶斯准则所需的概率：
 1. 相对频率方法 (“**客观**”). 概率只能通过实验得到
 2. 贝叶斯方法 (“**主观**”). 概率值可以反映某种程度的信念，可以基于实验也可以基于某种观点

例子

- 对鲈鱼和三文鱼进行分类
- 特征 x : 鱼的亮度
- 根据贝叶斯准则, 我们需要计算

$$P(\omega_j | x) = \frac{p(x | \omega_j)P(\omega_j)}{p(x)}$$

- 需要

$$p(x | \omega_j) \text{ 和 } P(\omega_j), \quad j = 1, 2$$

例子

通过收集的数据确定先验概率：对两类雨的数量进行计数并计算.

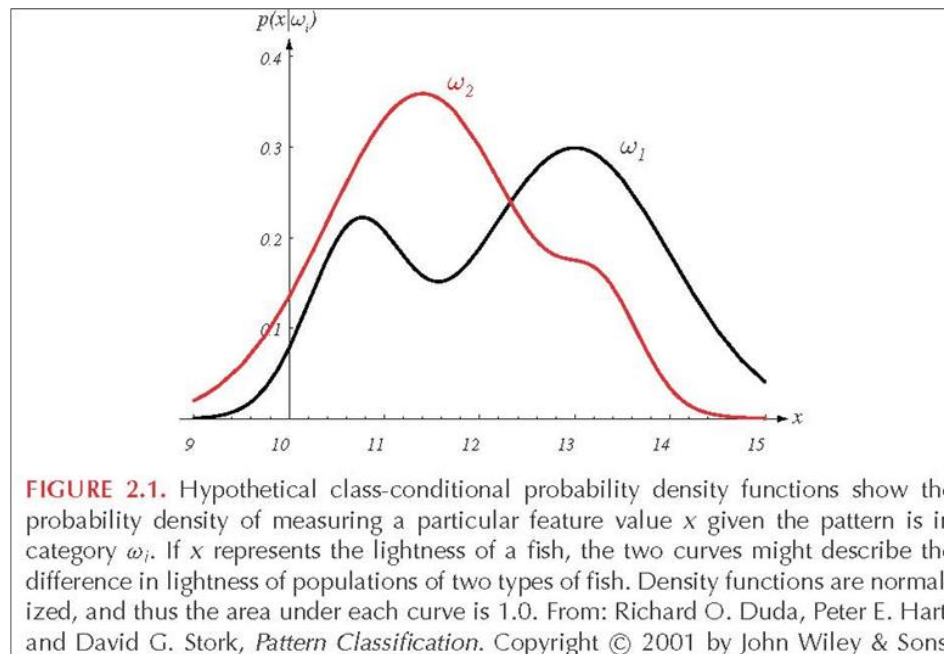
例如, 1000个样本: $\#\omega_1 = 900, \#\omega_2 = 100$

$$P(\omega_1) = \frac{900}{1000} = 0.9$$

$$P(\omega_2) = \frac{100}{1000} = 0.1$$

例子

- 确定类条件概率密度（似然） $p(x|\omega_j)$ ($j = 1, 2$)
 - 离散化鱼的亮度值，使其落入某个小的区间，并使用归一化的直方图



如对某个 x ，可得到 $p(x|\omega_1) = 0.2$ 和 $p(x|\omega_2) = 0.4$

例子

- 计算后验概率

$$P(\omega_1 | x) = \frac{p(x | \omega_1)P(\omega_1)}{\sum_{j=1}^2 p(x | \omega_j)P(\omega_j)} = \frac{0.2 \times 0.9}{0.2 \times 0.9 + 0.4 \times 0.1} = 0.818$$

$$P(\omega_2 | x) = 1 - P(\omega_1 | x) = 0.182$$

朴素贝叶斯

朴素贝叶斯基本方法

- 训练数据集: $T = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$
 - 由 X 和 Y 的联合概率分布 $P(X, Y)$ 独立同分布产生
 - 朴素贝叶斯通过训练数据集学习联合概率分布 $P(X, Y)$,
 - 即先验概率分布: $P(Y = c_k), k = 1, 2, \dots, K$
 - 及条件概率分布: $P(X = \mathbf{x} | Y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)} | Y = c_k), k = 1, 2, \dots, K$
- 于是学习到了联合分布概率
- 注意: 条件概率为指数级别的参数: $K \prod_{j=1}^n S_j$

朴素贝叶斯基本方法

- 条件独立性假设:

$$P(X = \mathbf{x} \mid Y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)} \mid Y = c_k) = \prod_{j=1}^n P(X^{(j)} = x^{(j)} \mid Y = c_k)$$

- “朴素”贝叶斯名字由来，牺牲分类准确性

- 贝叶斯定理: $P(Y = c_k \mid X = \mathbf{x}) = \frac{P(X=\mathbf{x}|Y=c_k)P(Y=c_k)}{\sum_k P(X=\mathbf{x}|Y=c_k)P(Y=c_k)}$

- 代入上式: $P(Y = c_k \mid X = \mathbf{x}) = \frac{P(Y=c_k) \prod_j P(X^{(j)}=x^{(j)}|Y=c_k)}{\sum_k P(Y=c_k) \prod_j P(X^{(j)}=x^{(j)}|Y=c_k)}$

朴素贝叶斯基本方法

- 贝叶斯分类器:

$$y = f(\mathbf{x}) = \arg \max_{c_k} \frac{P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}{\sum_k P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)}$$

- 分母对所有 c_k 都相同:

$$y = \arg \max_{c_k} P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)} | Y = c_k)$$

后验概率最大化的含义：

- 朴素贝叶斯法将实例分到后验概率最大的类中，等价于期望风险最小化，假设选择0 – 1损失函数： $f(X)$ 为决策函数

$$L(Y, f(X)) = \begin{cases} 1, & Y \neq f(X) \\ 0, & Y = f(X) \end{cases}$$

- 期望风险函数： $R_{\text{exp}}(f) = E[L(Y, f(X))]$
- 取条件期望： $R_{\text{exp}}(f) = E_X \sum_{k=1}^K [L(c_k, f(X))] P(c_k | X)$

后验概率最大化的含义：

- 只需对 $X = x$ 逐个极小化，得：

$$\begin{aligned} f(\mathbf{x}) &= \arg \min_{y \in \mathcal{Y}} \sum_{k=1}^K L(c_k, y) P(c_k | X = \mathbf{x}) \\ &= \arg \min_{y \in \mathcal{Y}} \sum_{k=1}^K P(y \neq c_k | X = \mathbf{x}) \\ &= \arg \min_{y \in \mathcal{Y}} (1 - P(y = c_k | X = \mathbf{x})) \\ &= \arg \max_{y \in \mathcal{Y}} P(y = c_k | X = \mathbf{x}) \end{aligned}$$

- 推导出后验概率最大化准则： $f(\mathbf{x}) = \arg \max_{c_k} P(c_k | X = \mathbf{x})$

朴素贝叶斯法的参数估计

应用极大似然估计法估计相应的概率

- 先验概率 $P(Y = c_k)$ 的极大似然估计是: $P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i=c_k)}{N}, k = 1, 2, \dots, K$
- 设第 j 个特征 $x^{(j)}$ 可能取值的集合为: $\{a_{j1}, a_{j2}, \dots, a_{js_j}\}$
- 条件概率的极大似然估计: $P(X^{(j)} = a_{jl} \mid Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)}=a_{jl}, y_i=c_k)}{\sum_{i=1}^N I(y_i=c_k)}$

$$j = 1, 2, \dots, n; \quad l = 1, 2, \dots, S_j; \quad k = 1, 2, \dots, K$$

朴素贝叶斯法的参数估计

朴素贝叶斯法:

- 输入:

- 训练数据集 $T = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_N, y_N)\}$

- $x_i^{(j)}$ 第 i 个样本的第 j 个特征: $x_i = (x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(n)})^T$

- a_{jl} 第 j 个特征可能取的第 l 个值 $x_i^{(j)} \in \{a_{j1}, a_{j2}, \dots, a_{js_j}\}$

- 输出:

- \mathbf{x} 的分类 $y_i \in \{c_1, c_2, \dots, c_K\}$

朴素贝叶斯法的参数估计

步骤

1、计算先验概率和条件概率

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N}, k = 1, 2, \dots, K$$

$$P(X^{(j)} = a_{jl} \mid Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)}$$

$$j = 1, 2, \dots, n; \quad l = 1, 2, \dots, S_j; \quad k = 1, 2, \dots, K$$

朴素贝叶斯法的参数估计

步骤

2、对于给定的实例 $\mathbf{x} = (x^{(1)}, x^{(2)}, \dots, x^{(n)})^T$

计算 $P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} \mid Y = c_k), k = 1, 2, \dots, K$

3、确定 \mathbf{x} 的类别

$$y = \arg \max_{c_k} P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} \mid Y = c_k)$$

例子


Day	Outlook	Temperature	Humidity	Wind	PlayTennis
1	Sunny	Hot	High	Weak	No
2	Sunny	Hot	High	Strong	No
3	Overcast	Hot	High	Weak	Yes
4	Rain	Mild	High	Weak	Yes
5	Rain	Cool	Normal	Weak	Yes
6	Rain	Cool	Normal	Strong	No
1	Overcast	Cool	Normal	Strong	Yes
8	Sunny	Mild	High	Weak	No
9	Sunny	Cool	Normal	Weak	Yes
10	Rain	Mild	Normal	Weak	Yes
11	Sunny	Mild	Normal	Strong	Yes
12	Overcast	Mild	High	Strong	Yes
13	Overcast	Hot	Normal	Weak	Yes
14	Rain	Mild	High	Strong	No

例子

测试

<Outlook=sunny, Temperature=cool, Humidity=high, Wind=strong>

$$c(x) = \arg \max_{c \in \{yes, no\}} P(c)P(\text{sunny} \mid c)P(\text{cool} \mid c)P(\text{high} \mid c)P(\text{strong} \mid c)$$



例子

$$P(\text{yes}) = (9 + 1)/(14 + 2) = 10/16$$

$$P(\text{no}) = (5 + 1)/(14 + 2) = 6/16$$

$$P(\text{sunny} \mid \text{yes}) = (2 + 1)/(9 + 3) = 3/12$$

$$P(\text{sunny} \mid \text{no}) = (3 + 1)/(5 + 3) = 4/8$$

$$P(\text{cool} \mid \text{yes}) = (3 + 1)/(9 + 3) = 4/12$$

$$P(\text{cool} \mid \text{no}) = (1 + 1)/(5 + 3) = 2/8$$

$$P(\text{high} \mid \text{yes}) = (3 + 1)/(9 + 2) = 4/11$$

$$P(\text{high} \mid \text{no}) = (4 + 1)/(5 + 2) = 5/7$$

$$P(\text{strong} \mid \text{yes}) = (3 + 1)/(9 + 2) = 4/11$$

$$P(\text{strong} \mid \text{no}) = (3 + 1)/(5 + 2) = 4/7$$

$$P(\text{yes})P(\text{sunny} \mid \text{yes})P(\text{cool} \mid \text{yes})P(\text{high} \mid \text{yes})P(\text{strong} \mid \text{yes}) = 0.0069$$

$$P(\text{no})P(\text{sunny} \mid \text{no})P(\text{cool} \mid \text{no})P(\text{high} \mid \text{no})P(\text{strong} \mid \text{no}) = 0.0191$$

贝叶斯估计

考虑用极大似然估计可能会出现所要估计的**概率值为0**的情况，这时会影响到后验概率的计算结果，使分类产生偏差。解决这一问题的方法是采用**贝叶斯估计**。

- 条件概率的贝叶斯估计：
$$P_{\lambda}(X^{(j)} = a_{jl} \mid Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k) + \lambda}{\sum_{i=1}^N I(y_i = c_k) + S_j \lambda}$$
- 先验概率的贝叶斯估计：
$$P_{\lambda}(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K \lambda}$$

作业

假设有两对不同的骰子，一对是标准的骰子（每个面的点数为1到6中的一个），另一对为“增广”的骰子，每个面的点数都增加了两个（介于3到8个点）。游戏者甲从一个装有60%标准对和40%增广对的袋子里随机选择一对进行投掷，游戏者乙在没有骰子信息的情况下，通过获知点数的和进行决策。

问题1：应如何决策，使平均错误概率最小化？最小平均错误概率是多少？

*问题2：如果乙猜对是标准骰子对，可获得10元钱，猜对是增广骰子对获得30元钱，猜错损失10元钱，应如何决策，平均风险如何？

作业

问题： 性别分类

训练样本：

Person	height (feet)	weight (lbs)	foot size(inches)
male	6	180	12
male	5.92 (5'11")	190	11
male	5.58 (5'7")	170	12
male	5.92 (5'11")	165	10
female	5	100	6
female	5.5 (5'6")	150	8
female	5.42 (5'5")	130	7
female	5.75 (5'9")	150	9

测试样本：

Person	height (feet)	weight (lbs)	foot size(inches)
sample	6	130	8

谢谢各位同学！