

# 模式识别与统计学习作业

---

学号：19001353  
姓名：丁一鸣

## 1.1 混淆矩阵与评价指标

Listing 1.1: Insert code directly in your document

```

1 import numpy as np
2 import matplotlib.pyplot as plt
3 from sklearn import metrics
4 import csv
5
6 # read the data
7 with open('score.csv', newline='') as f:
8     reader = csv.reader(f)
9     s = list(reader)
10 tmp = s[0]
11 scores = np.array([float(item) for item in tmp])
12 with open('label.csv', newline='') as f:
13     reader = csv.reader(f)
14     l = list(reader)
15 tmp = l[0]
16 label = np.array([float(item) for item in tmp])
17
18 # build confusion matrix with a threshold of 0.05
19 threshold = 0.05
20 label_pred=scores.copy()
21 label_pred[scores>threshold]=1
22 label_pred[scores<threshold]=0
23 cm = metrics.confusion_matrix(label, label_pred)
24 disp = metrics.ConfusionMatrixDisplay(confusion_matrix=cm)
25 disp.plot()
26 plt.show()
27
28 # get TP, FP, TN, FN from confusion matrix
29 TN = cm[0][0]
30 FN = cm[1][0]
31 TP = cm[1][1]
32 FP = cm[0][1]
33
34 # compute Precision, Recall, F1-score and Accuracy
35 P=TP/(TP+FP)
36 R=TP/(TP+FN)
37 F1=(2*P*R)/(P+R)
38 acc=(TP+TN)/len(label)
39 print("Precision: ",P,"nRecall: ",R,"nF1-score: ",F1,"nAccuracy: ",
      acc)

```

```
40
41 # compute FPR, TPR, AUC and draw ROC curve
42 fpr, tpr, thresholds = metrics.roc_curve(label, scores, pos_label=1)
43 print(thresholds)
44 roc_auc = metrics.auc(fpr, tpr)
45 plt.plot(
46     fpr,
47     tpr,
48     color="darkorange",
49     label="ROC curve (area= %0.2f)" % roc_auc,
50 )
51 plt.plot([0, 1], [0, 1], color="navy", linestyle="—")
52 plt.xlim([0.0, 1.0])
53 plt.ylim([0.0, 1.05])
54 plt.xlabel("False Positive Rate")
55 plt.ylabel("True Positive Rate")
56 plt.title("Receiver operating characteristic example")
57 plt.legend(loc="lower right")
58 plt.show()
```

## 2.1 条件独立性证明

定义:  $A$  和  $B$  在给定事件  $C$  的条件下相互独立, 如果

$$P(A, B | C) = P(A | C)P(B | C)$$

证明: 事件  $A$ ,  $B$  和  $C$  在给定事件  $C$  的条件下相互独立, 当且仅当  $P(C) > 0$ , 且

$$P(A | B, C) = P(A | C)$$

证明: “ $\Rightarrow$ ”: 因为  $A$ ,  $B$  和  $C$  在给定事件  $C$  的条件下相互独立, 根据定义有

$$P(A, B | C) = P(A | C)P(B | C)$$

又有  $P(C) > 0$ , 则

$$\begin{aligned} P(A | B, C) &= P(A, B | C) \frac{P(B | C)}{P(B | C)} \\ &= \frac{P(A, B, C)}{P(B | C)} \\ &= \frac{\frac{P(A, B, C)}{P(C)}}{\frac{P(B | C)}{P(C)}} \\ &= \frac{P(A, B | C)}{P(B | C)} \\ &= P(A | C) \end{aligned}$$

“ $\Leftarrow$ ”: 显然, 当

$$P(A | B, C) = P(A | C)$$

两边同乘  $P(B | C)$ , 则有定义式。

## 2.2 骰子问题

假设有两对不同的骰子, 一对是标准的骰子 (每个面的点数为 1 到 6 中的一个), 另一对为 “增广” 的骰子, 每个面的点数都增加了两个 (介于 3 到 8 个点)。游戏者甲从一个装有 60% 标准对和 40% 增广对的袋子里随机选择一对进行投掷, 游戏者乙在没有骰子信息的情况下, 通过获知点数的和进行决策。

1. 应如何决策，使平均错误概率最小化？最小平均错误概率是多少？
2. 如果乙猜对是标准骰子对，可获得 10 元钱，猜对是增广骰子对获得 30 元钱，猜错损失 10 元钱，应如何决策，平均风险如何？

## 2.3 性别分类问题

训练样本：

Person	height (feet)	weight (lbs)	foot size(inches)
male	6	180	12
male	5.92 (5'11")	190	11
male	5.58 (5'7")	170	12
male	5.92 (5'11")	165	10
female	5	100	6
female	5.5 (5'6")	150	8
female	5.42 (5'5")	130	7
female	5.75 (5'9")	150	9

测试样本：

Person	height (feet)	weight (lbs)	foot size(inches)
sample	6	130	8

Figure 2.1: 性别分类数据

## 最小二乘线性回归

### 3.1 糖尿病数据的回归与预测

## 4.1 FashionMNIST 数据的分类

## 5.1 打网球数据的分类

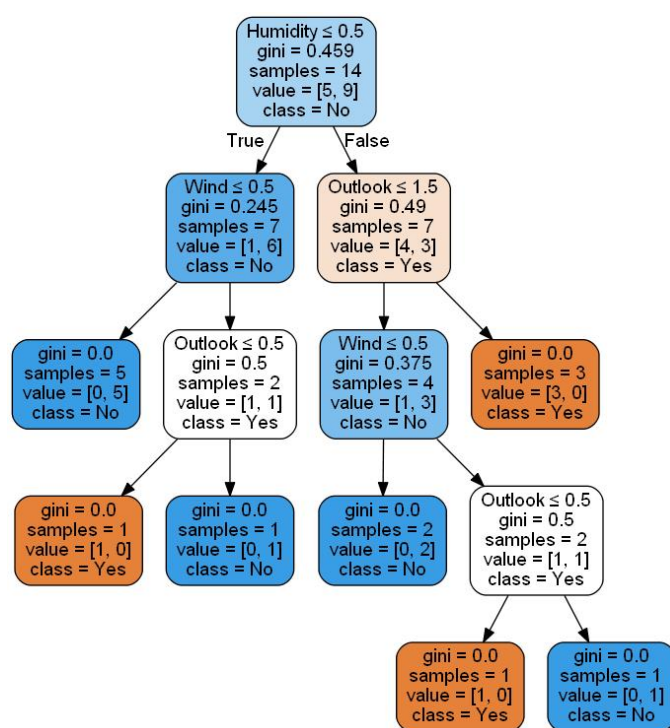


Figure 5.1: Decision tree of tennis data

Listing 5.1: Insert code directly in your document

```

1 from sklearn import tree
2 import pydotplus
3 import csv
4 f = csv.reader(open('1111.csv', 'r'))
5 # Outlook (0:Rain, 1:Overcast, 2:Suuny)
6 # Temperature (0:Cool, 1:Mild, 2:Hot)

```




```
7 # Humidity (0:Normal, 1:High)
8 # Wind (0:Weak, 1:Strong)
9 X = [[2,2,1,0],
10      [2,2,1,1],
11      [1,2,1,0],
12      [0,1,1,0],
13      [0,0,0,0],
14      [0,0,0,1],
15      [1,0,0,1],
16      [2,1,1,0],
17      [2,0,0,0],
18      [0,1,0,0],
19      [2,1,0,0],
20      [1,1,1,1],
21      [1,2,0,0],
22      [0,1,1,1]]
23 y = [0,0,1,1,1,0,1,0,1,1,1,1,1,0]
24
25
26 # 建立并训练决策树
27 clf = tree.DecisionTreeClassifier()
28 clf = clf.fit(X, y)
29
30 # 预测结果
31 dot_data = tree.export_graphviz(clf, out_file=None,
32                                 feature_names=['Outlook', 'Temprature', 'Humidity',
33                                                'Wind'],
34                                 class_names=['Yes', 'No'],
35                                 filled=True, rounded=True,
36                                 special_characters=True)
37 graph = pydotplus.graph_from_dot_data(dot_data)
38 graph.write_jpg("tree.jpg") # 生成jpg文件
```

## 5.2 不纯度指数的计算

### 不纯度指数(Impurity Index)

- ① Entropy:  $\sum_{j=1}^K p_j \ln \frac{1}{p_j}$ .
- ② Misclassification rate:  $1 - \max_j p_j$ .
- ③ Gini index:  $\sum_{j=1}^K p_j(1-p_j) = 1 - \sum_{j=1}^K p_j^2$ .



针对属性A的两个分支和属性B的两个分支，分别计算以香农熵，错误率和Gini指数作为不纯度指数时的信息增益，并说明在此信息增益下，应选择哪个属性生成子节点。

Figure 5.2: 不纯度计算题目

解：

1. Entropy
- 2.