



模式识别与机器学习

4. 15、 Softmax判据的概念



引言

逻辑回归输出：属于正类的后验概率

$$\text{sigmoid}(\boldsymbol{w}^T \boldsymbol{x} + w_0) = p(C_1 | \boldsymbol{x})$$

引言



对于多类而言，
每类的后验概率如何表达？



后验概率：多类情况

一个类与剩余类的后验概率比率

- 逻辑回归是由Logit变换反推出来的。
- 由Logit变换可知：正负类后验概率比率的对数是一个线性函数。

$$\ln \frac{p(C_1|\mathbf{x})}{p(C_2|\mathbf{x})} = \mathbf{w}^T \mathbf{x} + w_0 \Rightarrow \frac{p(C_1|\mathbf{x})}{p(C_2|\mathbf{x})} = \exp(\mathbf{w}^T \mathbf{x} + w_0)$$

- 分类 K 个类，可以构建 K 个线性判据。第 i 个线性判据表示 C_i 类与剩余类的分类边界，剩余类用一个参考负类（reference class） C_K 来表达。

$$\frac{p(C_i|\mathbf{x})}{p(C_K|\mathbf{x})} = \exp(\mathbf{w}_i^T \mathbf{x} + w_{0i}) \quad \text{where } K \neq i$$



后验概率：多类情况

参考类的后验概率 $p(C_K|\mathbf{x})$

- 由于所有类别后验概率之和为1，参考类 C_K 的后验概率为：

$$p(C_K|\mathbf{x}) = 1 - \sum_{i=1}^{K-1} p(C_i|\mathbf{x})$$
$$\frac{p(C_i|\mathbf{x})}{p(C_K|\mathbf{x})} = \exp(\mathbf{w}_i^T \mathbf{x} + w_{0i})$$

$$= 1 - p(C_K|\mathbf{x}) \sum_{i=1}^{K-1} \exp(\mathbf{w}_i^T \mathbf{x} + w_{0i})$$

$$\Rightarrow p(C_K|\mathbf{x}) = \frac{1}{1 + \sum_{i=1}^{K-1} \exp(\mathbf{w}_i^T \mathbf{x} + w_{0i})}$$



后验概率：多类情况

任意正类的后验概率 $p(C_i|\mathbf{x})$

- 任意正类 $C_i (i \neq K)$ 的后验概率为：

$$\frac{p(C_i|\mathbf{x})}{p(C_K|\mathbf{x})} = \exp(\mathbf{w}_i^T \mathbf{x} + w_{0i})$$

$$\Rightarrow p(C_i|\mathbf{x}) = \frac{\exp(\mathbf{w}_i^T \mathbf{x} + w_{0i})}{1 + \sum_{j=1}^{K-1} \exp(\mathbf{w}_j^T \mathbf{x} + w_{0j})}$$

后验概率：多类情况

重新审视参考负类的后验概率 $p(C_K|\mathbf{x})$

- 把 $p(C_K|\mathbf{x})$ 参照 $p(C_i|\mathbf{x})$ 的形式，可以类比得到：

$$\left. \begin{aligned} p(C_K|\mathbf{x}) &= \frac{1}{1 + \sum_{j=1}^{K-1} \exp(\mathbf{w}_j^T \mathbf{x} + w_{0j})} \\ p(C_i|\mathbf{x}) &= \frac{\exp(\mathbf{w}_i^T \mathbf{x} + w_{0i})}{1 + \sum_{j=1}^{K-1} \exp(\mathbf{w}_j^T \mathbf{x} + w_{0j})} \end{aligned} \right\} \Rightarrow \exp(\mathbf{w}_K^T \mathbf{x} + w_{0K}) = 1$$

$$\mathbf{w}_K^T \mathbf{x} + w_{0K} = 0$$



后验概率：多类情况

任意类的后验概率 $p(C_i|\mathbf{x})$

- 因此，得到任意一个类的后验概率 $p(C_i|\mathbf{x})$ ：

$$p(C_i|\mathbf{x}) = \frac{\exp(\mathbf{w}_i^T \mathbf{x} + w_{0i})}{\sum_{j=1}^K \exp(\mathbf{w}_j^T \mathbf{x} + w_{0j})}, \quad i = 1, 2, \dots, K$$

- 可见，对于多类分类 ($K > 2$)， K 个线性模型也跟每个类对应的后验概率建立起了联系。



Softmax函数

Softmax函数

$$\text{softmax: } z_i = \frac{\exp(y_i)}{\sum_{j=1}^K \exp(y_j)}, \quad i = 1, 2, \dots, K$$

- 该后验概率计算方法被称作softmax函数：
 - ✓ 如果一个类 C_i 对应的 y_i （即线性模型的输出）远远大于其他类的，经过exp函数和归一化操作，该类的后验概率 $p(C_i|x)$ 接近于1，其他类的后验概率接近于0，则softmax决策就像是一个max函数。
 - ✓ 但是，该函数又是可微分的，所以称作“软最大值函数”。



Softmax判据

Softmax判据

- Softmax判据： K 个线性判据 + softmax函数。

Softmax判据的决策过程

- 给定测试样本 \mathbf{x} ，经由线性模型和softmax函数计算 K 个类对应的后验概率， \mathbf{x} 属于最大后验概率对应的类别。

$$l(\mathbf{x}) = \arg \max_i p(C_i | \mathbf{x}) = \arg \max_i \frac{\exp(\mathbf{w}_i^T \mathbf{x} + w_{0i})}{\sum_{j=1}^K \exp(\mathbf{w}_j^T \mathbf{x} + w_{0j})}$$

决策边界

Softmax判据的决策边界


- Softmax判据用于分类，等同于基于one-to-all策略的线性机。
 - ✓ 决策区域相邻的两类 C_i 和 C_j ，它们的决策边界 H_{ij} 为线性：

$$p(C_i|\mathbf{x}) = p(C_j|\mathbf{x})$$

$$\Rightarrow \exp(\mathbf{w}_i^T \mathbf{x} + w_{0i}) = \exp(\mathbf{w}_j^T \mathbf{x} + w_{0j})$$


$$\Rightarrow \mathbf{w}_i^T \mathbf{x} + w_{0i} = \mathbf{w}_j^T \mathbf{x} + w_{0j}$$

$$\Rightarrow (\mathbf{w}_i - \mathbf{w}_j)^T \mathbf{x} + (w_{0i} - w_{0j}) = 0$$



Softmax判据决策示例


- $K = 3$
- 细线：3条线性方程 $\mathbf{w}_i^T \mathbf{x} + w_{0i}$ ；粗线：softmax判据决策边界。



Softmax判据与神经网络

Softmax判据与神经网络

- 相当于由 K 个神经元组成的神经网络输出层，每个神经元输出值代表属于该类的后验概率 $p(C_i|\mathbf{x}) \in [0,1]$ 。
- 注意： $\sum_{i=1}^K p(C_i|\mathbf{x}) = 1$



- Softmax判据的决策过程可以进一步表达为：

$$l(\mathbf{x}) = \arg \max_i \text{softmax}(\mathbf{W}\mathbf{x} + \mathbf{w}_0)$$

$$\text{where } \mathbf{W} = [\mathbf{w}_1, \dots, \mathbf{w}_K]^T, \mathbf{w}_0 = [w_{01}, \dots, w_{0K}]^T$$

对比：线性机模型



适用范围

适用范围：分类

- 前提：每个类和剩余类之间是线性可分的。

适用范围：回归

- 范围：可以拟合指数函数（exp）形式的非线性曲线。

总结

- Softmax判据本身是一个非线性模型。
- Softmax判据用于分类：只能处理多个类别、每个类别与剩余类线性可分的情况。但是，Softmax判据可以输出后验概率。因此，Softmax判据比基于one-to-all策略的线性机向前迈进了一步。
- Softmax判据用于拟合：可以输出有限的非线性曲线。



模型对比

模型	线性判据	逻辑回归	Softmax判据	MAP分类器
模型表达	$\mathbf{w}^T \mathbf{x} + w_0$	$\text{sigmoid}(\mathbf{w}^T \mathbf{x} + w_0)$	$p(C_i \mathbf{x}) = \frac{\exp(\mathbf{w}_i^T \mathbf{x} + w_{0i})}{\sum_{j=1}^K \exp(\mathbf{w}_j^T \mathbf{x} + w_{0j})}$	$p(C_i \mathbf{x}) = \frac{p(\mathbf{x} C_i)p(C_i)}{p(\mathbf{x})}$
模型属性	线性	非线性	非线性	线性/非线性
决策边界	线性	线性	线性	线性/非线性
输出信号	几何距离	后验概率	后验概率	后验概率
分类	二类分类 (线性可分)	二类分类 (线性可分)	多类分类 (每类与剩余类线性可分)	多类分类 (线性可分/不可分)
回归	拟合线性	拟合非线性曲线 (sigmoid形)	拟合非线性曲线 (exp形)	--



Softmax判据如何学习?